

План подготовки Data Scientist с нуля: дорожная карта на 2026 год

Резюме

Путь от начального уровня Python и математики до первой позиции Data Scientist занимает **10–14 месяцев** при интенсивной учёбе по 12–15 часов в неделю. При вашем темпе **6–10 часов в неделю** срок реалистично растягивается до **18 месяцев** — это нормально и не снижает качество подготовки [1].

Ключевые выводы из исследования:

- **Математика нужна на уровне уверенной статистики и теории вероятностей**, а не университетского матанализа. Глубокая теория подтягивается по мере необходимости [1].
- **Практика важнее лекций**: работодатели в 2026 году ориентируются на портфолио из 3–5 реальных проектов, а не на сертификаты. Количество junior-вакансий сократилось (313 в 2023 → 121 в 2025, по данным hh.ru), и компании ищут специалистов с подтверждёнными навыками [2].
- **Современный Data Scientist обязан выходить за рамки классического ML**: понимание MLOps (Docker, Git, MLflow) и работа с LLM (векторные базы, RAG) становятся обязательными компетенциями [3][2].
- **Рынок ценит уникальную специализацию**: 73% работодателей положительно оценивают навыки работы с ИИ-инструментами и нейросетями [2].
- **Для старта достаточно**: Python, SQL, статистика, scikit-learn, pandas, Git и Jupyter Notebook [1].

Этап 1. Фундамент: математика, Python и работа с данными (месяцы 1–4)

1.1. Математическая база

Не пытайтесь выучить всю математику «про запас» — осваивайте темы по мере появления задач. Ключевые разделы для старта [1]:

Раздел	Что нужно знать	Зачем
Теория вероятностей	Случайные величины, распределения, условная вероятность, закон больших чисел	Понимание работы моделей, метрик, доверительных интервалов
Статистика	Среднее, дисперсия, корреляция, проверка гипотез, p-value	База для А/В-тестирования, оценки качества моделей

Раздел	Что нужно знать	Зачем
Линейная алгебра	Векторы, матрицы, операции над ними (на уровне понимания, без вывода теорем)	Понимание принципов работы алгоритмов и нейросетей
Матанализ (основы)	Производная, градиентный спуск (концептуально)	Понимание процесса обучения моделей

Рекомендуемые ресурсы:

- Открытый учебник по статистике (рекомендуется в [\[1\]](#))
- Курсы Stepik по теории вероятностей и статистике (ищите курсы с хорошим рейтингом и практическими заданиями)

1.2. Python до уверенного уровня

Что нужно уметь после этапа:

- Уверенно работать со списками, словарями, функциями, циклами, условиями
- Понимать ООП на базовом уровне (у вас уже есть обзорное знакомство — этого достаточно для старта)
- Работать с файлами (CSV, JSON)
- Использовать Jupyter Notebook для экспериментов

Ориентир: курс по Python на Stepik (например, «Поколение Python» или аналогичные) [\[1\]](#).

1.3. Библиотеки для анализа данных

Параллельно с Python осваивайте основной стек:

- **pandas** — обработка табличных данных (загрузка, фильтрация, группировка, join)
- **NumPy** — работа с массивами и математическими операциями
- **Matplotlib / Seaborn** — визуализация данных

Критерий готовности этапа: без подсказок загрузить CSV-файл и ответить на простые вопросы о данных (средние значения, распределения, пропуски) [\[1\]](#).

Этап 2. SQL и подготовка данных (месяцы 4–6)

SQL — **первый жёсткий фильтр при найме Data Scientist**. Без уверенного владения SELECT, JOIN, GROUP BY, оконными функциями и подзапросами большинство компаний не рассматривает резюме [\[2\]](#).

Что освоить:

- Базовые запросы: SELECT, WHERE, ORDER BY, LIMIT
- Агрегации: GROUP BY, HAVING, COUNT, SUM, AVG

- JOIN всех типов (INNER, LEFT, RIGHT, FULL)
- Подзапросы и CTE
- Оконные функции (ROW_NUMBER, RANK, LAG/LEAD)

Практика: используйте бесплатные тренажёры SQL (например, SQLite + задачи на Stepik или Codecademy), а затем переходите к реальным датасетам на Kaggle.

Этап 3. Классическое машинное обучение (месяцы 5–10)

3.1. Теоретическая база

Освойте фундаментальные концепции ML [\[1\]\[4\]](#):

- **Обучение с учителем:** регрессия (линейная, полиномиальная), классификация (логистическая регрессия, деревья решений, случайный лес, градиентный бустинг)
- **Обучение без учителя:** кластеризация (K-means, иерархическая), снижение размерности (PCA)
- **Оценка моделей:** train/test split, кросс-валидация, метрики (accuracy, precision, recall, F1, ROC-AUC)
- **Переобучение и регуляризация:** L1/L2, dropout (для нейросетей)
- **Работа с признаками:** фича-инжиниринг, обработка пропусков, масштабирование

3.2. Практические курсы

Курс	Платформа	Характеристика
«Введение в Data Science и машинное обучение» (Институт биоинформатики)	Stepik, stepik.org/4852	~9,5 часов видео, практика на pandas и scikit-learn, бесплатно [4]
«Машинное обучение»	Stepik, stepik.org/8057	~7 часов, понятно без глубокой математики, бесплатно [4]
Открытый курс машинного обучения (Open Data Science, ODS.ai)	ods.ai	Формат близкий к университетскому: лекции, дедлайны, общение в Slack, бесплатно [4]
Machine Learning Crash Course	Google	~15 часов, на русском, интерактивные упражнения [4]

Рекомендация: начните с курса на Stepik (stepik.org/8057) для целостного понимания, затем перейдите к курсу Института биоинформатики и завершите этап курсом ODS.ai, который даст более глубокую практику.

Этап 4. Первые проекты и Kaggle (месяцы 8–12)

4.1. Kaggle Learn

Бесплатные микрокурсы на Kaggle — идеальный инструмент, потому что вы сразу применяете технику на реальных данных [\[5\]](#).

4.2. Базовые проекты

Рекомендуемая последовательность для новичка [\[6\]](#):

1. **Titanic: предсказание выживаемости пассажиров** — классический первый проект, маленький датасет, основы классификации
2. **House Prices: предсказание стоимости жилья** — регрессия, работа с фичами, продвинутые техники (Random Forest, XGBoost)
3. **MNIST: распознавание рукописных цифр** — вход в deep learning, свёрточные сети
4. **Forest Cover Type Prediction** — мультиклассовая классификация

4.3. End-to-End проект

После базовых задач соберите полный продакшн-пайплайн [\[5\]](#):

1. **Сбор данных** — через API или веб-скрапинг (например, ваш любимый сервис, история прослушиваний Spotify, рейтинги фильмов)
 2. **Очистка и разведка данных** — pandas, визуализация
 3. **Обучение модели**
 4. **Оценка качества**
 5. **Деплой** — превратите модель в веб-приложение через Streamlit или Flask [\[5\]](#)
-

Этап 5. Углубление: Deep Learning и современные направления (месяцы 10–16)

5.1. Нейронные сети

Когда классические алгоритмы освоены, переходите к глубокому обучению. Подходящие русскоязычные курсы на Stepik [\[7\]](#):

- «Добрый, добрый ИИ. Часть 2. Нейронные сети на PyTorch» (Сергей Балакирев, 2026) — полный курс: полносвязные сети, CNN, RNN, LSTM, VAE, GAN, трансферное обучение. Выбор PyTorch обоснован удобством для исследований [\[7\]](#).
- «Практический Deep Learning» (Елена Кантонистова и др., 2025) — теоретические и практические основы нейросетей [\[7\]](#).
- «Нейронные сети: Основы глубокого обучения с нуля» (Валерий Никаноров, 2025) — для тех, кто хочет понять внутреннее устройство [\[7\]](#).

Что изучить:

- Полносвязные сети и backpropagation
- Свёрточные сети (CNN) для изображений
- Рекуррентные сети (RNN, LSTM, GRU) для последовательностей
- Автоэнкодеры и генеративные модели (VAE, GAN)
- Transfer Learning — дообучение предобученных моделей

5.2. MLOps и LLM — обязательные тренды 2026 года

По данным Habr, MLOps превратился из модного термина в обязательную дисциплину [3]. Рынок MLOps растёт на 40% ежегодно, а главный тренд 2026 года — интеграция больших языковых моделей (LLM) в продакшн [3].

Что нужно освоить после базовых навыков:

Инструмент	Назначение
Git	Версионирование кода
Docker	Контейнеризация моделей
MLflow / ClearML	Трекинг экспериментов
Airflow / Prefect	Оркестрация пайплайнов
Векторные БД + RAG	Работа с LLM в продакшне

Важно: MLOps-навыки делают кандидата заметно конкурентоспособнее и связаны с более высокими зарплатами (middle MLOps-инженер в Москве зарабатывает 280–420 тыс. ₽ против классического DS) [3].

Этап 6. Портфолио, стажировки и выход на рынок (месяцы 14–18)

6.1. Портфолио

Золотой стандарт: 3–5 качественных проектов на GitHub, а не 10 посредственных. Для каждого проекта обязателен README, где вы объясняете [5]:

- Какую бизнес-проблему решаете
- Где взяли данные
- Как очищали и исследовали данные
- Почему выбрали именно эти модели
- Каков итоговый результат

Идеи проектов: анализ истории прослушиваний, предсказание оттока клиентов, распознавание изображений, чат-бот на LLM [5].

6.2. Позиционирование на рынке

Рынок junior-позиций стал конкурентнее: число вакансий сократилось в 2,5 раза за 2023–2025 годы, поэтому решающее значение имеют [2]:

- Реальные проекты (а не сертификаты)
- Уверенный SQL
- Умение объяснять выводы нетехническим людям — это проверяется на собеседованиях
- Понимание A/B-тестирования и проверки гипотез (p-value, statsmodels) — это первый фильтр при найме [2]

6.3. Стажировки и первые шаги

- Отслеживайте стажировки в Яндексе, Сбере, Авито и других крупных компаниях — требования в них соответствуют описанному выше стеку [1]
- Участвуйте в соревнованиях Kaggle — даже участие без победы демонстрирует навыки
- Вступайте в сообщества: ODS.ai, профильные Telegram-каналы, митапы

Итоговая таблица этапов

Этап	Содержание	Длительность (при 6–10 ч/нед)	Ключевой результат
1. Фундамент	Python, математика, pandas, NumPy	3–5 месяцев	Загрузка и анализ CSV-файла без подсказок
2. SQL и данные	SQL, подготовка данных	1–2 месяца	Уверенные JOIN, GROUP BY, оконные функции
3. Классический ML	scikit-learn, регрессия, деревья, бустинг	3–5 месяцев	Понимание всех базовых алгоритмов
4. Практика	Kaggle, первые проекты	2–3 месяца	2–3 завершённых проекта
5. Deep Learning и MLOps	PyTorch, нейросети, Docker, Git	3–5 месяцев	Обученная нейросеть, развёрнутая в контейнере
6. Портфолио и рынок	GitHub, стажировки, собеседования	1–2 месяца	Портфолио из 3–5 проектов, готовность к офферу

Итоговая рекомендация

1. **Начните с курса Python на Stepik** и параллельно читайте учебник по статистике. Не пытайтесь выучить математику «про запас» — осваивайте темы по мере появления задач [\[1\]](#).
2. **Пройдите курсы по ML на Stepik** (сначала базовый stepik.org/8057, затем курс Института биоинформатики) и завершите этап курсом ODS.ai [\[4\]](#).
3. **Сразу после первых лекций начинайте практику на Kaggle** — первые проекты можно делать параллельно с теорией [\[6\]](#).
4. **Не пропускайте SQL** — это первый фильтр при найме [\[2\]](#).
5. **После классического ML переходите к Deep Learning** (PyTorch) и MLOps (Docker, Git, MLflow). Эти навыки выделяют вас среди других junior-кандидатов [\[3\]](#)[\[7\]](#).
6. **Соберите портфолио из 3–5 проектов** с качественными README и как минимум одним развёрнутым веб-приложением [\[5\]](#).
7. **Помните про мягкие навыки:** умение объяснять выводы бизнесу — ключевой фактор, который используют для отсева кандидатов на собеседованиях [\[2\]](#).

Ссылки:

[\[1\] https://checkroi.ru/blog/kak-stat-data-scientist/](https://checkroi.ru/blog/kak-stat-data-scientist/)

[\[2\] https://www.tgu-dpo.ru/news/2026/07/09/zarplata-analitika-dannykh/](https://www.tgu-dpo.ru/news/2026/07/09/zarplata-analitika-dannykh/)

[\[3\] https://habr.com/ru/articles/1035304/](https://habr.com/ru/articles/1035304/)

[\[4\] https://uproger.com/aktualnye-besplatnye-resursy-dlya-izucheniya-ii-i-mashinnogo-obucheniya-2026/](https://uproger.com/aktualnye-besplatnye-resursy-dlya-izucheniya-ii-i-mashinnogo-obucheniya-2026/)

[\[5\] https://pingax.com/data-scientist-beginner-tutorial/](https://pingax.com/data-scientist-beginner-tutorial/)

[\[6\] https://www.projectpro.io/article/kaggle-machine-learning-projects/823](https://www.projectpro.io/article/kaggle-machine-learning-projects/823)

[\[7\] https://rutorforum13.cc/threads/sergei-balakirev-stepik-dobryi-dobryi-ii-chast-2-neironnyye-seti-na-pytorch-2026.162484/](https://rutorforum13.cc/threads/sergei-balakirev-stepik-dobryi-dobryi-ii-chast-2-neironnyye-seti-na-pytorch-2026.162484/)